实验三：参数估计与非参数估计

实验学时： 4 学时（两次实验）
截止时间： 11 月 6 日
提交邮箱： machinelearning26@163.com

实验目的

1. 掌握参数估计方法在模式分类中的应用。
2. 理解非参数估计的基本原理和实现方法。
3. 比较参数方法和非参数方法在不同数据分布下的性能。
4. 分析先验概率对分类器性能的影响。

实验环境

- Python 3.8+
- 主要依赖库：NumPy、Matplotlib、SciPy、scikit-learn、Seaborn、Pandas
- 开发环境：Jupyter Notebook / PyCharm / VS Code

数据集设置

分布参数

生成三个数据集，每个数据集包含四个二维高斯分布类别：

均值向量：

$$\boldsymbol{\mu}_1 = [1, 2], \quad \boldsymbol{\mu}_2 = [3, 5], \quad \boldsymbol{\mu}_3 = [6, 3], \quad \boldsymbol{\mu}_4 = [4, 7]$$

协方差矩阵：

$$\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}_3 = \boldsymbol{\Sigma}_4 = 1.5\mathbf{I}$$

其中，$\mathbf{I}$ 为 2×2 单位矩阵。

先验概率设置

数据集	先验类型	$p(\omega_1)$	$p(\omega_2)$	$p(\omega_3)$	$p(\omega_4)$	总样本数
A	均衡先验	0.25	0.25	0.25	0.25	1200
B	偏斜先验 1	0.5	0.2	0.2	0.1	1200
C	偏斜先验 2	0.1	0.1	0.3	0.5	1200

实验要求

初级要求：多类别参数估计与分类性能分析

实验内容：

1. 按照指定参数生成三个数据集 A、B、C。
2. 在每个数据集上实现并应用以下四类别分类规则：
    - 似然率测试规则
    - 最大后验概率（MAP）规则
3. 计算并比较总体分类错误率、每个类别的分类准确率，并给出混淆矩阵。
4. 绘制三个数据集的样本分布散点图，不同类别使用不同颜色。

分析要求：

- 对比不同先验概率设置对分类性能的影响。
- 分析两种分类规则在四类别问题中的表现差异。
- 讨论类别间重叠区域对分类性能的影响。

中级要求：核密度估计的带宽选择与泛化评估

实验内容：

1. 使用高斯核密度估计对四个类别分别估计概率密度。
2. 对每个数据集按类别分层划分训练集和测试集，比例为 **8:2**；固定并记录随机种子。高级要求沿用同一划分。
3. 仅使用训练集进行**分层 5 折交叉验证**，在 $h \in \{0.1, 0.3, 0.5, 0.8, 1.0, 1.5, 2.0\}$ 中选择带宽。每一折中，只用该折的训练部分估计密度，在验证部分计算分类错误率；分别为似然率测试规则和 MAP 规则选择平均验证错误率最低的 h。MAP 规则使用题目给定的类别先验概率。
4. 选定带宽后，使用完整训练集重新估计各类别密度，并在测试集上评估两种分类规则；报告总体错误率和各类别准确率。
5. 绘制各数据集、两种分类规则在不同 h 下的交叉验证错误率；选择有代表性的带宽展示密度估计效果，并比较交叉验证结果与测试集结果。

分析要求：

- 分析带宽 h 对分类结果的影响，并说明选择的带宽是否能在测试集上保持较好的表现。
- 比较三个数据集及两种分类规则选出的带宽，讨论类别先验对分类结果的影响。
- 讨论核密度估计在多类别问题中的适用性。

高级要求：k-近邻密度估计与分类比较

实验内容：

1. 实现按类别估计条件概率密度的 k-近邻密度估计方法。查询点到第 k 个近邻的距离只根据训练集中对应类别的样本计算。
2. 沿用中级要求的训练集和测试集划分；对测试样本估计各类别密度，并使用似然率测试规则和 MAP 规则分类。MAP 规则使用题目给定的类别先验概率。
3. 测试 $k \in \{1, 3, 5, 8, 10\}$，报告各数据集、两种分类规则在测试集上的总体错误率和各类别准确

率。绘制不同 k 值下的错误率比较图，并选择一个数据集展示代表性的密度等高线或分类区域图。

分析要求：

- 分析 k 值对密度估计平滑程度及分类结果的影响。
- 比较 k-近邻方法在不同先验分布下的表现。
- 讨论 k-近邻方法在类别边界处的表现特点。

核心公式

多元高斯分布（参数估计）

$$p(\mathbf{x} \mid \omega_i) = \frac{1}{(2\pi)^{d/2}|\mathbf{\Sigma}_i|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_i)^T \mathbf{\Sigma}_i^{-1}(\mathbf{x}-\boldsymbol{\mu}_i)\right]$$

似然率测试规则

$$\hat{\omega}(\mathbf{x}) = \arg\max_i p(\mathbf{x} \mid \omega_i)$$

MAP 规则

$$\hat{\omega}(\mathbf{x}) = \arg\max_i p(\mathbf{x} \mid \omega_i) p(\omega_i)$$

高斯核密度估计

$$\hat{p}(\mathbf{x} \mid \omega_i) = \frac{1}{n_i h^d} \sum_{j=1}^{n_i} \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|\mathbf{x}-\mathbf{x}_{ij}\|^2}{2h^2}\right)$$

其中 n_i 是训练集中类别 ω_i 的样本数，$d=2$，h 为带宽。

k-近邻密度估计

$$\hat{p}(\mathbf{x} \mid \omega_i) = \frac{k}{n_i V_d(r_k)}$$

其中 r_k 是到第 k 个近邻的距离，$V_d(r_k)$ 是半径为 r_k 的 d 维球体体积。

提交要求

提交格式参照之前发的实验说明。

重要提示

1. 中级和高级共用每个数据集的训练集、测试集划分。测试集只用于最终评估，不参与带宽或 k 值选择；中级带宽通过训练集上的交叉验证确定。
2. 绘图、指标计算等可使用常用 Python 库；似然率规则、MAP 规则、核密度估计和 k-近邻密度估计的核心计算应自行实现。