实验二：白葡萄酒质量回归

实验学时： 4 学时（两次实验）
截止时间： 10 月 23 日
提交邮箱： machinelearning26@163.com

实验目标

使用白葡萄酒的理化指标建立线性回归模型，预测葡萄酒质量评分；通过批量梯度下降和随机梯度下降优化模型，并比较学习率和正则化对预测效果的影响。

数据集

文件： `winequality-white.csv`
来源： UCI Machine Learning Repository — Wine Quality 数据集（白葡萄酒子集）

文件格式

- CSV 文本文件，字段之间以**分号** `;` 分隔，而不是逗号。
- 每行是一份白葡萄酒样本；首行为字段名。
- 标准白葡萄酒数据集包含 **4,898 条样本、12 列**：11 个理化指标和 1 个质量评分。
- 输入特征为前 11 列，目标变量为 `quality`。
- `quality` 是离散整数评分（标准数据中为 0–10 的评分尺度；实际出现的评分取值以文件为准），本任务将其作为数值型回归目标。

实验要求

基本要求

将 `winequality-white.csv` 数据集按 **4:1** 划分为训练集和测试集。

1. 构造线性回归模型，分别采用**批量梯度下降（BGD）**和**随机梯度下降（SGD）**进行优化；输出训练集和测试集的均方误差（MSE），并绘制 MSE 收敛曲线。
2. 对 BGD 和 SGD 分别尝试不同的学习率，展示不同学习率下的 MSE 曲线，并分析、选择较合适的学习率。
3. 划分数据集时尽量保持数据分布一致；可考虑按目标评分进行分层抽样。
4. 对数据集进行一定的预处理。

实现建议： 如对特征进行标准化或归一化，可先用训练集确定变换参数，再用于测试集。

中级要求

1. **比较优化方法：** 比较 BGD 和 SGD 的测试集 MSE，并结合收敛曲线简要说明两者在误差、收敛速度或稳定性上的差异。
2. **分析特征影响：** 选择至少 **3 个特征**，根据标准化模型的系数或特征扰动后的预测变化，说明它们

与质量评分预测的关系。

3. **特征相关性实验：** 根据训练集的 Pearson 相关系数选出最相关的一对特征。标准化后，比较保留两者和移除其中一个特征时的模型系数与测试集 MSE，分析相关特征对系数稳定性和预测效果的影响。

高级要求

编程实现**岭回归（Ridge Regression，L2 正则化）**，求解训练样本上的岭回归模型，并报告平均训练误差和平均测试误差。可选择以下任一种方法求解：

- 解析法
- 批量梯度下降法
- 随机梯度下降法

核心公式

多元线性回归

$h_\theta(\mathbf{x}) = \theta_0 + \sum_{j=1}^{p} \theta_j x_j$

将偏置项并入特征向量后，可写作 $h_\theta(\mathbf{x}) = \mathbf{x}^T\theta$。本数据集的特征数 $p = 11$。

均方误差

$\mathrm{MSE}(\theta) = \frac{1}{m}\sum_{i=1}^{m}\left(h_\theta(\mathbf{x}^{(i)}) - y^{(i)}\right)^2$

批量梯度下降

$\theta \leftarrow \theta - \alpha\frac{2}{m}X^T(X\theta - y)$

随机梯度下降

每次抽取一个样本 $(\mathbf{x}^{(i)}, y^{(i)})$ 更新参数：

$\theta \leftarrow \theta - 2\alpha\mathbf{x}^{(i)}\left(\mathbf{x}^{(i)T}\theta - y^{(i)}\right)$

岭回归

$J(\theta) = \frac{1}{m}\|X\theta - y\|_2^2 + \lambda\sum_{j=1}^{p}\theta_j^2$

通常不惩罚偏置项 θ_0；实现时应在报告中注明采用的约定。

提交要求

提交格式参照之前发的实验说明。

重要提示

⚠️ **线性回归的核心实现必须手写！**

禁止用于自己的实现：

- `sklearn.linear_model.LinearRegression`
- `sklearn.linear_model.SGDRegressor`
- `sklearn.linear_model.Ridge`
- `sklearn.linear_model.Lasso`

允许使用：

- `numpy`、`pandas`、`matplotlib`（基础工具）
- `sklearn.metrics`（评估指标计算）
- `sklearn.preprocessing`（数据预处理）
- `sklearn.model_selection`（数据划分与交叉验证）
- 上述 sklearn 模型仅用于对比验证